



Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Querétaro

TC3007C

Inteligencia artificial avanzada para la ciencia de datos II

## **ETAPA DE EVALUACIÓN**

**Autores:**

A01368818 Joel Sánchez Olvera

A01661090 Juan Pablo Cabrera Quiroga

A01704076 Adrián Galván Díaz

A01708634 Carlos Eduardo Velasco Elenes

A01709522 Arturo Cristián Díaz López

**Fecha:**

22 de noviembre del 2024

## **Introducción**

La etapa de evaluación en la metodología CRISP-DM es crucial para validar si los modelos desarrollados cumplen con los objetivos establecidos, tanto a nivel técnico como de negocio. Durante esta fase, se analizan los resultados obtenidos a partir de los modelos implementados, evaluando su desempeño con base en las métricas clave, y se examina su alineación con los objetivos de minería de datos y de negocio. Además, esta etapa busca identificar áreas de mejora y proponer ajustes necesarios para optimizar el sistema.

El objetivo principal de esta evaluación es garantizar que los resultados generados no solo sean precisos y confiables, sino que también proporcionen valor en términos de análisis de datos y toma de decisiones. En el contexto del proyecto CAETEC, se busca verificar que el sistema desarrollado permita cuantificar y caracterizar la población ganadera en función de su postura y ubicación, además de facilitar la integración de estos resultados en los flujos de trabajo operativos a través de bases de datos accesibles y formatos estándar.

## **Marco de evaluación**

### **Objetivos de negocio.**

Determinar la ocupación de los espacios destinados al descanso de las vacas en el rancho, identificando la población de ganado en cada zona y evaluando qué áreas están ocupando la mayor parte del tiempo.

### **Criterios de éxito**

1. Se identifica el número total de vacas dentro de un área específica en la imagen (conteo de población).
2. Se mapea la distribución de vacas en el espacio geográfico asignado para evaluar la ocupación de los espacios.
3. Los registros generados por el sistema son accesibles y disponibles en formatos comunes para la visualización y análisis de datos.

## Objetivos de minería de datos

Desarrollar un modelo de detección y clasificación de vacas que permita cuantificar y caracterizar la población ganadera según su postura (parada/acostada) en las diferentes áreas del rancho.

### Criterios de éxito

1. El modelo de detección de vacas cumple con lo siguiente:
  - Precisión  $\geq 90\%$  en el conteo total de vacas por imagen
  - IoU (Intersection over Union)  $\geq 0.75$  en la detección de vacas individuales
2. El modelo de clasificación de vacas debe alcanzar:
  - Precisión  $\geq 85\%$  en la clasificación de posturas (parada/acostada)
  - F1-Score  $\geq 0.80$  para cada clase de postura
  - Error máximo de  $\pm 5\%$  en el conteo total de población
3. La solución final debe realizar el procesamiento de una imagen en un tiempo no mayor a 5000 milisegundos.

## Proceso de Evaluación

El proceso de evaluación se realizó a través de múltiples iteraciones, donde cada modelo fue evaluado contra los criterios establecidos y refinado según necesidad. La evaluación siguió un enfoque sistemático que incluyó:

1. Desarrollo inicial de modelos
2. Evaluación contra criterios técnicos y de negocio
3. Refinamiento o cambio de enfoque según resultados
4. Validación final de los modelos seleccionados

## Desarrollo y Evaluación de Modelos

### Iteraciones del proyecto

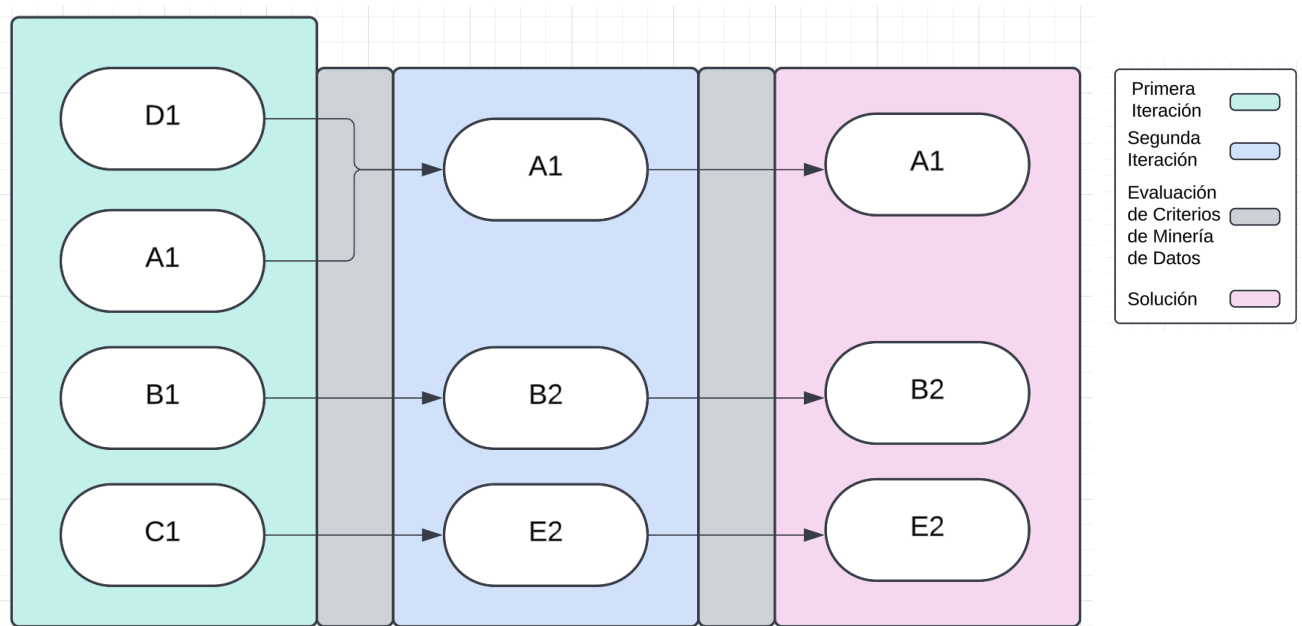
Durante el desarrollo del proyecto, se implementaron múltiples modelos que evolucionaron a través de dos iteraciones principales. Cada iteración fue guiada por los criterios de éxito establecidos y la retroalimentación obtenida de las evaluaciones previas. El proceso iterativo permitió:

1. Desarrollar modelos en paralelo para comparar diferentes enfoques tecnológicos

2. Refinar modelos existentes para mejorar su rendimiento
3. Realizar cambios fundamentales de enfoque cuando fue necesario

A continuación, se presenta un diagrama que ilustra la evolución de los diferentes modelos y sus relaciones:

### DIAGRAMA DE ITERACIONES



Como se observa en el diagrama, el desarrollo se dividió en las siguientes líneas de trabajo:

- Modelos de identificación de vacas (A1 y D1): Desarrollados en paralelo para comparar diferentes frameworks
- Modelo de clasificación de posturas (B1 → B2): Refinado para mejorar la precisión
- Modelo de análisis de patrones (C1 → E2): Rediseñado con un nuevo enfoque metodológico

En las siguientes secciones, se detalla la evaluación de cada modelo y las decisiones tomadas en base a los criterios establecidos.

## Modelo A1 (Bounding Box Detection)

### Decisión Final

Se eligió el modelo YOLOv5 (A1) como la solución final para la detección de vacas en imágenes.

### Razones detrás de la elección

Cumplimiento de los objetivos de minería de datos:

- Precisión en el conteo total de vacas: El modelo alcanzó una precisión del 98.7%, superando ampliamente el umbral requerido de 90%.
- $IoU \geq 0.75$ : El  $mAP@0.5$  obtenido fue del 97.5%, asegurando un excelente desempeño en la calidad de las detecciones individuales.
- Consistencia en las métricas: Un  $mAP@0.5:0.95$  del 80% confirmó que el modelo funciona bien incluso bajo criterios más estrictos.

### Confiabilidad

El  $mAP@0.5$  final refleja una adecuada optimización del modelo, mostrando robustez y capacidad de generalización.

### Limitaciones del modelo D1:

El modelo SSD MobileNet (D1) mostró métricas perfectas en teoría ( $mAP$  de 1.0 a  $IoU=0.5$ ), pero un rendimiento deficiente en pruebas prácticas, indicando inconsistencias y sobreajuste.

### Impacto en el proyecto

El modelo A1 garantiza una detección precisa y confiable de las vacas en las imágenes, cumpliendo los requerimientos técnicos y proporcionando una base sólida para la integración con otros modelos en etapas posteriores.

Modelo	Precisión	mAP	¿Los resultados son confiables?	¿Se cumplen los objetivos de negocio?	¿Se cumplen los objetivos de minería de datos?
<b>A1 Modelo de Detección con Pytorch</b>	0.987	0.975	Sí. En las imágenes de prueba que se le pasó al modelo entrenado detectó correctamente todas las vacas en las imágenes	Sí	Sí
<b>D1 Modelo de Detección con Tensor Flow</b>	NA	1	No. El modelo tuvo un pobre desempeño al identificar las vacas en las imágenes de prueba que se le pasaron.	No	No

## Modelo B2 (Clasificación de Posturas)

### Decisión Final

El modelo PyTorch Classifier (B2) fue seleccionado tras la iteración de mejora del modelo inicial (B1).

### Razones detrás de la elección

Cumplimiento de los objetivos de minería de datos:

- Precisión promedio: El modelo alcanzó una precisión del 98.6%, superando el umbral requerido de 85%.
- F1-Score por clase: El modelo logró un 97.8%, excediendo el mínimo establecido de 80%.
- Eficiencia temporal: Procesó cada imagen en menos de 5000 ms, cumpliendo con el requerimiento no funcional.

### Mejoras implementadas:

Migración de TensorFlow a PyTorch, permitiendo un mejor rendimiento y una velocidad de entrenamiento mejorada en el modelo.

### Limitaciones del modelo inicial (B1):

Aunque B1 mostró un rendimiento y un accuracy aceptables, cuando fue probado en datos reales, cometió errores no triviales al clasificar ambas posturas, indicando dificultades de generalización.

### Impacto en el proyecto

El modelo B2 proporciona una solución confiable y eficiente para clasificar posturas de vacas, integrándose perfectamente con el modelo de detección para análisis posteriores.

Modelo	Precisión	F1 Score	¿Los resultados son confiables?	¿Se cumplen los objetivos de negocio?	¿Se cumplen los objetivos de minería de datos?
<b>B2 Modelo de clasificación de posiciones con Pytorch</b>	97.80%	98.60%	Sí. El modelo tiene una buena precisión y se ve reflejado en las pruebas con condiciones reales.	Sí. El modelo nos dice con una buena precisión y confianza, el estado actual del ganado	Sí. El modelo presenta un accuracy mayor al umbral de 85%
<b>B1 Modelo de clasificación de posiciones con Tensorflow</b>	96.43%	96%	No. El modelo de clasificación presenta una buena precisión, sin embargo al probarlo en condiciones reales, las predicciones no son acertadas.	Sí. El modelo nos dice el estado actual del ganado	Sí. El modelo presenta un accuracy mayor al umbral de 85%

## Modelo E2 (Análisis de Patrones en la Arena)

### Decisión Final

El modelo E2 se seleccionó tras un cambio de enfoque respecto al modelo inicial (C1).

### Razones detrás de la elección

Cumplimiento de los objetivos de minería de datos:

- Precisión en detección de bordes: Los métodos Sobel, Canny y Laplaciano superaron el umbral de 90%.
- Validación de patrones: Contraste alto y homogeneidad cercana a cero revelaron patrones texturales significativos, alineándose con los criterios establecidos.

### Cambio de enfoque respecto a C1:

El modelo inicial se centró en la identificación de patrones para el área de descanso, pero E2 adoptó un enfoque dinámico para identificar interacciones significativas en cada cama, lo que resultó en hallazgos más útiles para la gestión.

### Impacto en el proyecto

El modelo E2 ofrece un análisis detallado y práctico de los patrones de uso en cada cama de descanso, proporcionando información clave para optimizar su mantenimiento y gestión.

Modelo	Métricas	¿Los resultados son confiables?	¿Se cumplen los objetivos de negocio?	¿Se cumplen los objetivos de minería de datos?
<b>E2 Modelo de análisis de patrones en arena (singular)</b>	<b>Contraste</b> $\approx$ 100 unidades <b>Homogeneidad:</b> cercana a 0 <b>Degradación de escala:</b> 0.011 a 0.004 <b>Detección de bordes:</b> Alta densidad de características en los tres métodos	Sí, el modelo muestra consistencia en todas sus métricas y los patrones detectados son confirmados por múltiples métodos de análisis.	Sí, el modelo identifica efectivamente un uso intensivo y dinámico del espacio, proporcionando información valiosa para la gestión y mantenimiento de la cama.	Sí
<b>C1 Modelo de análisis de patrones en arena (múltiple)</b>	<b>Detección de bordes:</b> Alta densidad de características en los tres métodos <b>Contraste</b> $\approx$ 15 unidades <b>Homogeneidad</b> $<$ 3 unidades <b>Degradación de escala:</b> 0.00445 a 0.00275 <b>Detección de bordes:</b> Consistencia entre los tres métodos	Sí, los resultados muestran consistencia a través de diferentes escalas y son validados por múltiples métodos de detección.	Sí, el modelo confirma la ausencia de patrones problemáticos y valida el uso eficiente de los espacios de descanso a través de múltiples camas.	Sí

## Modelos aprobados

Como se demostró en la sección anterior, los modelos desarrollados cumplen satisfactoriamente con los criterios de éxito establecidos tanto a nivel técnico como de negocio. El modelo de detección de vacas permite identificar y contar con precisión las bounding boxes, mientras que el modelo de clasificación caracteriza la postura de las vacas en cada área monitoreada, enriqueciendo estos registros con información clave como su ubicación y precisión. Por su parte, el análisis de patrones en camas de arena complementa la solución proporcionada al socio como anexo.

Además, los resultados generados permiten satisfacer los objetivos de minería de datos, proporcionando información clave sobre la ocupación y uso de las áreas de descanso generando registros detallados en la base de datos. El conjunto de modelos construidos para la solución final permiten que se identifique la población de ganado en cada zona y evaluar qué áreas están ocupando la mayor parte del tiempo.

Los registros generados por la integración de los modelos y la base de datos se pueden consultar en [esta carpeta](#).



Como socio formador, doy validez del cumplimiento de los siguientes objetivos de negocio, reconozco el valor y el trabajo puestos en el proyecto por el equipo "NoName" en la solución del reto establecido:

**Objetivo de negocio:**

"Determinar la ocupación de los espacios destinados al descanso de las vacas en el rancho, identificando la población de ganado en cada zona y evaluando qué áreas están ocupando la mayor parte del tiempo."

**Criterios de éxito:**

1. Se identifica el número total de vacas dentro de un área específica en la imagen (conteo de población).
2. Se mapea la distribución de vacas en el espacio geográfico asignado para evaluar la ocupación de los espacios.
3. Los registros generados por el sistema son accesibles y disponibles en formatos comunes para la visualización y análisis de datos.

---

Firma del socio formador



## Revisión del proceso

El proceso de minería de datos siguió todas las etapas de CRISP-DM de manera estructurada, garantizando un flujo claro desde la comprensión del negocio hasta la implementación y evaluación de los modelos. Sin embargo, se identificó que la etapa de modelado tomó más tiempo del recomendado debido a la necesidad de realizar iteraciones exhaustivas para ajustar cada modelo. Este enfoque, aunque prolongado, aseguró la robustez y confiabilidad de los resultados obtenidos.

Durante el desarrollo de los modelos, se encontraron puntos de mejora en las primeras iteraciones o versiones, las cuales fueron solucionadas a través de ajustes documentados.

Un área de mejora clave fue la forma en que se manejaron las iteraciones. En lugar de realizar múltiples ciclos cortos de modelado como recomienda CRISP-DM, se realizó una única iteración prolongada que tomó aproximadamente seis semanas. Aunque este enfoque funcionó en este proyecto, formalizar las iteraciones en ciclos más cortos hubiera permitido una mayor adaptabilidad y velocidad en la corrección de errores, lo que constituye una oportunidad para futuros proyectos.

## Lista de posibles acciones

Una posible acción futura es integrar los análisis de patrones de arena con los criterios de éxito de minería de datos. Esto permitiría generar insights más valiosos al analizar no solo la ocupación de los espacios, sino también cómo las texturas y patrones de uso impactan la calidad de los descansos y el bienestar de los animales.

Los recursos actuales son suficientes para implementar esta acción. Sin embargo, el desafío principal no radica en los recursos materiales o técnicos, sino en gestionar mejor el tiempo asignado para completar el proyecto dentro de los plazos establecidos.

Se recomienda formalizar las iteraciones en proyectos futuros, dividiendo las fases largas como el modelado en ciclos más pequeños y manejables. Esto permitirá:

- Mayor flexibilidad para realizar ajustes.
- Identificar problemas más rápidamente y evitar tiempos prolongados en una sola fase.
- Mantener un mejor control sobre el cronograma del proyecto.

## **Decisión**

Después de analizar las posibles acciones, se decidió no llevar a cabo la integración de los análisis de patrones de arena con los resultados de los modelos de minería de datos. Esta decisión se tomó considerando el tiempo limitado restante para completar el proyecto.

En lugar de realizar la integración propuesta, se optó por enfocar los esfuerzos en proporcionar insights de valor directamente alineados con las necesidades del socio formador. Esta decisión permite comprender de manera más eficiente las prioridades del negocio, entregando resultados claros, accionables y en un formato accesible que pueda ser implementado de inmediato. Este enfoque asegura que los objetivos del proyecto se cumplan dentro de los plazos establecidos, maximizando el impacto para el socio.